In [45]:
```
!pip install pystemmer
import os
import re
import wordcloud as  WorldCloud
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import plotly.express as px
import plotly.graph_objects as go
from plotly.offline import init_notebook_mode,iplot
init_notebook_mode(connected = True)
import Stemmer
from sklearn.feature_extraction.text import CountVectorizer
import plotly.io as pio
pio.renderers.default = 'notebook'
```

```
Requirement already satisfied: pystemmer in /opt/conda/lib/python3.10/site-packages (2.2.0.1)
```

Read the data

In [46]:
```
path_names=os.listdir("/kaggle/input/hespress")
```

In [ ]:
```
df=pd.DataFrame()
for data_csv in path_names :
    if data_csv.startswith('stories_'):
        df=df.append(pd.read_csv("/kaggle/input/hespress/"+data_csv))
```

In [48]:
```
df.head()
```

Out[48]:

	Unnamed: 0	id	title	date	author	story	topic
0	0	9d9ebd0204f811eb92ec646e69d991ea	شهادة طبيب جراح "تورط" قنصلا بتر أصبع مسنة	الجمعة 02 أكتوبر 2020 - 20:08	هسبريس من الدار البيضاء	قررت الغرفة الجنائية بمحكمة الاستئناف بمدينة ا...	faits-divers
1	1	9e96ecc604f811eb836a646e69d991ea	إحباط تهريب أكثر من طن من "الحشيش" بأكادير	الجمعة 02 أكتوبر 2020 - 19:37	رشيد بيجيكن من أكادير	... تمكنت المصلحة الولائية للشرطة القضائية بمدينة	faits-divers
2	2	9fc1ec4204f811eb8619646e69d991ea	كمين أمن الصويرة يسقط شبكة هجرة غير نظامية	الجمعة 02 أكتوبر 2020 - 18:35	ابراهيم مغراوي من مراكش	أوقفت عناصر فرقة الشرطة القضائية بالمنطقة الإق...	faits-divers
3	3	a0a2fa9c04f811eb8580646e69d991ea	تلميذة زاكورة" تتهم زوج أختها باستغلالها جنسيا"	الجمعة 02 أكتوبر 2020 - 14:20	هسبريس من زاكورة	كشف مصدر أمني مسؤول أن التلميذة المتحدرة من جم...	faits-divers
4	4	a2d0124a04f811eba88f646e69d991ea	أحجار كريمة مزيفة" تورط أشخاصا بمدينة أكادير"	الجمعة 02 أكتوبر 2020 - 10:05	رشيد بيجيكن من أكادير	تمكنت عناصر المصلحة الولائية للشرطة القضائية ب...	faits-divers

In [49]:
```
def describe(df):
    sum_null_values = df.isnull().sum()
    percent_null_values = 100* (sum_null_values/len(df))
    data_type = df.dtypes
    unique_values = df.nunique()

    table = pd.concat([sum_null_values,percent_null_values,data_type,unique_values], axis=1)
    table_col = table.rename(columns = {0 : 'Missing Values', 1 : '% of Total Missing Values', 2 : 'Data_Type', 3: 'Unique values'})
    return table_col
```

In [50]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 11000 entries, 0 to 999
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype 
---  ------      --------------  ----- 
 0   Unnamed: 0  11000 non-null  int64 
 1   id          11000 non-null  object
 2   title       11000 non-null  object
 3   date        11000 non-null  object
 4   author      11000 non-null  object
 5   story       11000 non-null  object
 6   topic       11000 non-null  object
dtypes: int64(1), object(6)
memory usage: 687.5+ KB
```

In [51]:
```
df.isnull().sum()
```

Out[51]:
```
Unnamed: 0    0
id            0
title         0
date          0
author        0
story         0
topic         0
dtype: int64
```

In [52]:
```
print(f"number of examples is: {len(df)}")
```

```
number of examples is: 11000
```

Remove unnecessary columns

In [53]:
```
df.drop(["Unnamed: 0","id","title","date","author"], axis=1,inplace=True)
```

In [54]:
```
df.head()
```

Out[54]:

	story	topic
0	قررت الغرفة الجنائية بمحكمة الاستئناف بمدينة ا...	faits-divers
1	تمكنت المصلحة الولائية للشرطة القضائية بمدينة ...	faits-divers
2	أوقفت عناصر فرقة الشرطة القضائية بالمنطقة الإق...	faits-divers
3	كشف مصدر أمني مسؤول أن التلميذة المتحدرة من جم...	faits-divers
4	تمكنت عناصر المصلحة الولائية للشرطة القضائية ب...	faits-divers

Pre-Proccessing

First look about top 100 freq words

In [55]:
```
freq_words=df["story"].str.split(expand=True).stack().value_counts()
top_100_freq_words=freq_words[:100]

fig=px.treemap(top_100_freq_words,path=[top_100_freq_words.index],values=0)
fig.update_layout(title="Word Frequency",title_x=0.5)
fig.show()

## we compare this figure after pre-processing

## as it classification problem we can pre-process the text by removing stop words, normalizing words, etc.. any sutitable pre-process method
```

Word Frequency

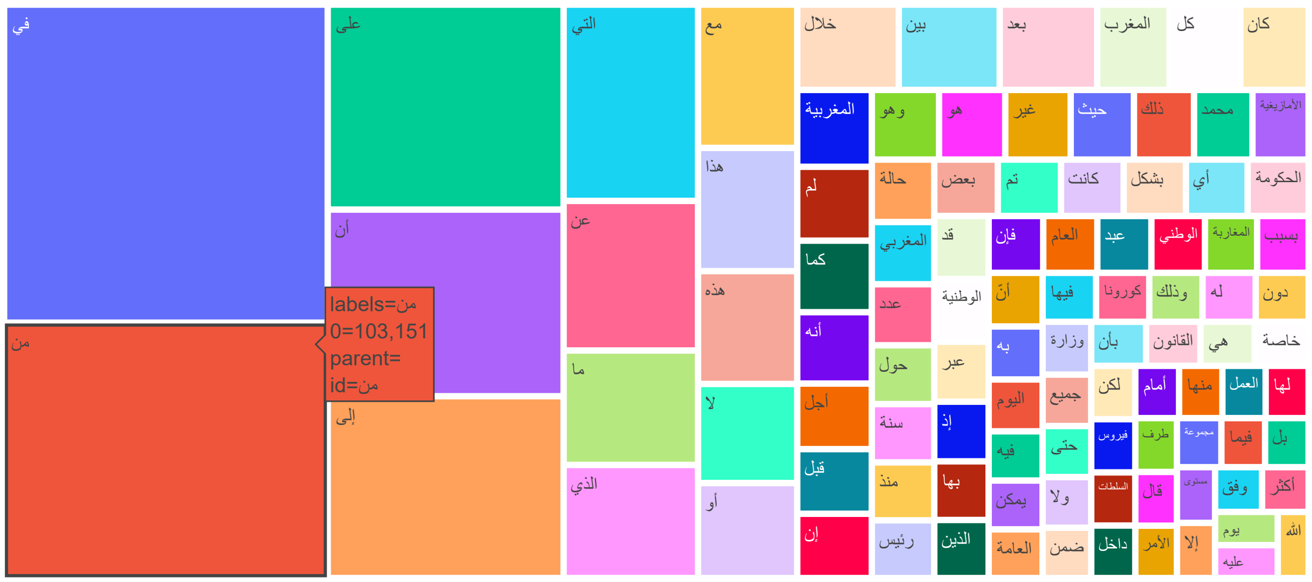

In [56]:
```
stop_words =['من',
 'في',
 'على',
 'و',
 'فى',
 'يا',
 'عن',
 'مع',
 'ان',
 'هو',
 'علي',
 'ما',
 'اللي',
 'كل',
 'بعد',
 'ده',
 'اليوم',
 'أن',
 'يوم',
 'انا',
 'إلى',
 'كان',
 'ايه',
 'اللى',
 'الى',
 'دي',
 'بين',
 'انت',
 'أنا',
 'حتى',
 'لما',
 'فيه',
 'هذا',
 'واحد',
 'احنا',
 'اي',
 'كده',
 'إن',
 'او',
 'أو',
 'عليه',
 'ف',
 'دى',
 'مين',
 'الي',
 'كانت',
 'أمام',
 'زي',
 'يكون',
 'خلال',
 'ع',
 'كنت',
 'هي',
 'فيها',
'عند',
'التي',
'الذي',
'قال',
'هذه',
'قد',
'انه',
'ريتويت',
'بعض',
'أول',
'ايه',
'الان',
'أي',
'منذ',
'عليها',
'له',
'ال',
'تم',
'ب',
'دة',
'عليك',
'اى',
'كلها',
'اللتى',
'هى',
'دا',
'انك',
'وهو',
'ومن',
'منك',
'نحن',
'زى',
'أنت',
'انهم',
'معانا',
'حتي',
'وانا',
'عنه',
'إلي',
'ونحن',
'وانت',
'منكم',
'وان',
'معاهم',
'معايا',
'وأنا',
'عنها',
'إنه',
'اني',
'معك',
'اننا',
'فيهم',
'د',
'انتا',
 'عنك',
 'وهى',
 'معا',
 'آن',
 'انتي',
 'وأنت',
 'وإن',
 'ومع',
 'وعن',
 'معاكم',
 'معاكو',
 'معاها',
 'وعليه',
 'وانتم',
 'وانتي',
 'ۀ',
 '|']
```

In [57]:
```python
def remove_stop_words(text):
    '''
    Argument:
        string of words
    return:
        string of words but without stop words
    '''
    return " ".join(word for word in text.split() if word not in stop_words)
```

In [58]:
```python
def normalize(sentence):
    '''
    Argument:
        string of words
    return:
        string of words but standardize the words
    '''
    sentence = re.sub("[إأآا]", "ا", sentence)
    sentence = re.sub("ى", "ي", sentence)
    sentence = re.sub("ؤ", "ء", sentence)
    sentence = re.sub("ئ", "ء", sentence)
    sentence = re.sub("ة", "ه", sentence)
    sentence = re.sub("گ", "ك", sentence)
    return sentence
```

In [59]:
```
def pre_process_text(text):
    '''
    Argument:
        string of words
    return:
        string of cleaned words
    '''
    st =  Stemmer.Stemmer('arabic')
    text = text.replace("#", " ");
    text = text.replace("@", " ");
    text = text.replace("_", " ");
    text = text.replace('"', ' ');
    text = text.replace('،', ' ');
    text = re.sub(r'\s+', ' ', text) # This line replaces one or more consecutive whitespace characters (\s+) with a single space. It effecti
    text=remove_stop_words(text)
    text=normalize(text)
    text= " ".join([st.stemWord(i) for i in text.split()])
    return text
```

In [60]:
```
pre_process_texts=[pre_process_text(text) for text in df["story"]]
df["story"]=pre_process_texts
```

Data Analysis

In [61]:
```
freq_words=df["story"].str.split(expand=True).stack().value_counts()
top_100_freq_words=freq_words[:100]

fig=px.treemap(top_100_freq_words,path=[top_100_freq_words.index],values=0)
fig.update_layout(title="Word Frequency",title_x=0.5)
fig.show()

## so the words are different after cleaning the texts,
##noted that methods in data preprocessing like stop_words or stemming may not be suitable for other use cases
```

Word Frequency

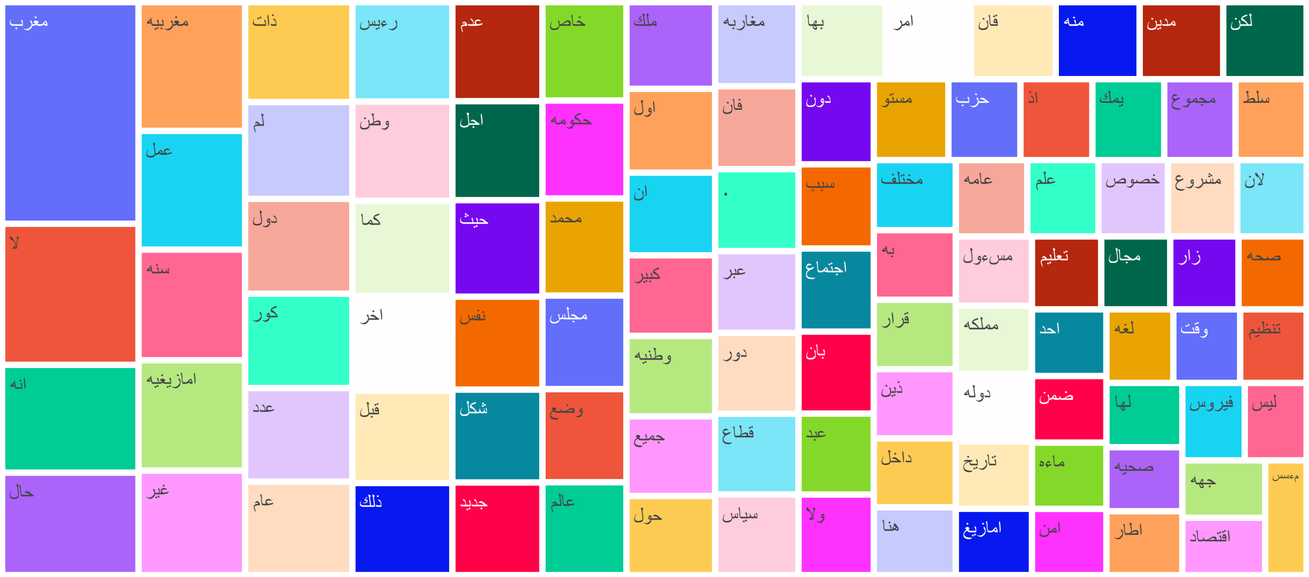

Distribution of words

In [62]:
```
df["text length"]=[len(t.split(" ")) for t in df["story"]]
fig=px.histogram(df["text length"],marginal='box',labels={"value" :"Text Length"})
fig.update_traces(marker=dict(line=dict(color='rgba(12, 50, 196, 0.6)',width=2)))
fig.update_layout(title_text="Distribution of words",title_x=0.5)

## so from that the Distribution is right skewed and there are outliers and the text lengths avearge are in 249
```

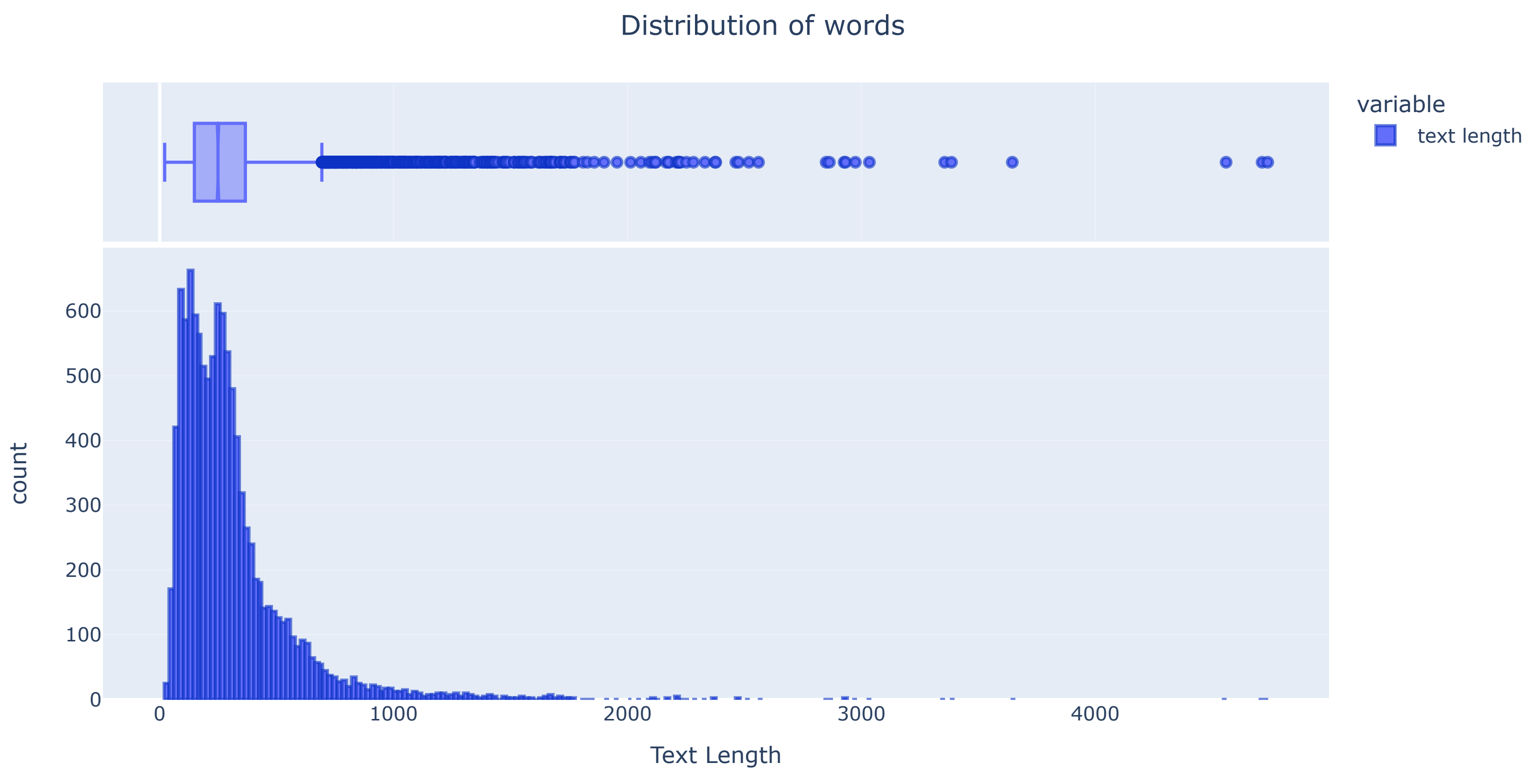

Distribution of topics `

In [63]:
```
fig=px.histogram(df["topic"],labels={"value" :"Topics"},color=df["topic"])
fig.update_traces(marker=dict(line=dict(color='rgba(12, 50, 196, 0.6)',width=2)))
fig.update_layout(title_text="Distribution of topics",title_x=0.5)

## from that we know that the data is balanced and no need for data augmentation, but in future we can need to increase the dataset itself
```

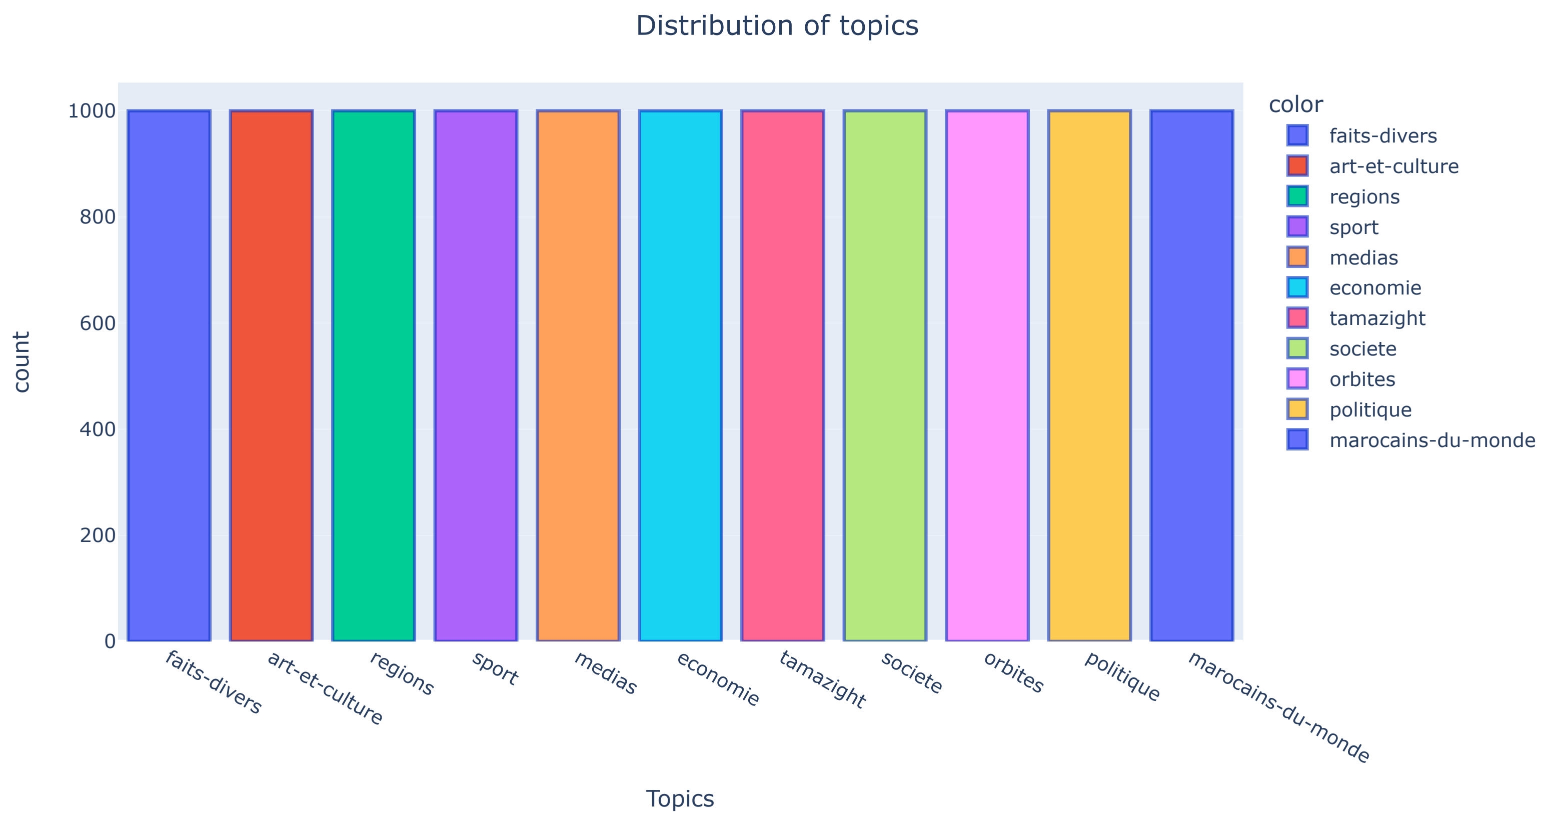

Distribution of N-Gram

```
In [64]: def get_top_n_words(texts,n,n_gram):
             doc=CountVectorizer(ngram_range=(n_gram,n_gram)).fit(texts)  # convert a collection of text documents into a matrix of token counts (word
             bow=doc.transform(texts) # transform the input dataset into a bag-of-words (BOW) representation. The BOW matrix will have rows representi
             sum_words=bow.sum(axis=0) #  calculates the sum of word occurrences across all documents in the BOW matrix
             word_freq=[(word,sum_words[0,idx]) for word,idx in doc.vocabulary_.items()] # know the word and its occurrences
             word_freq=sorted(word_freq,key =lambda x:x[1],reverse=True) ##sort them in descending order
             return word_freq[:n]
```

Unigram

In [65]:
```
words=get_top_n_words(df["story"],100,1)
df_gram=pd.DataFrame(words,columns=["Bigram","Count"])
data = go.Bar(
                x = df_gram["Bigram"],
                y = df_gram["Count"],
                name = "citations",
                marker = dict(color = 'rgba(255, 174, 255, 0.5)',
                             line=dict(color='rgb(0,0,0)',width=1.5)))
fig = go.Figure(data = data)
fig.update_xaxes(tickangle= 45)
fig.update_layout(title_text="Distribution of Unigram",title_x=0.5)
iplot(fig)

## now we see the top 100 words unigram distribution
```

Distribution of Unigram

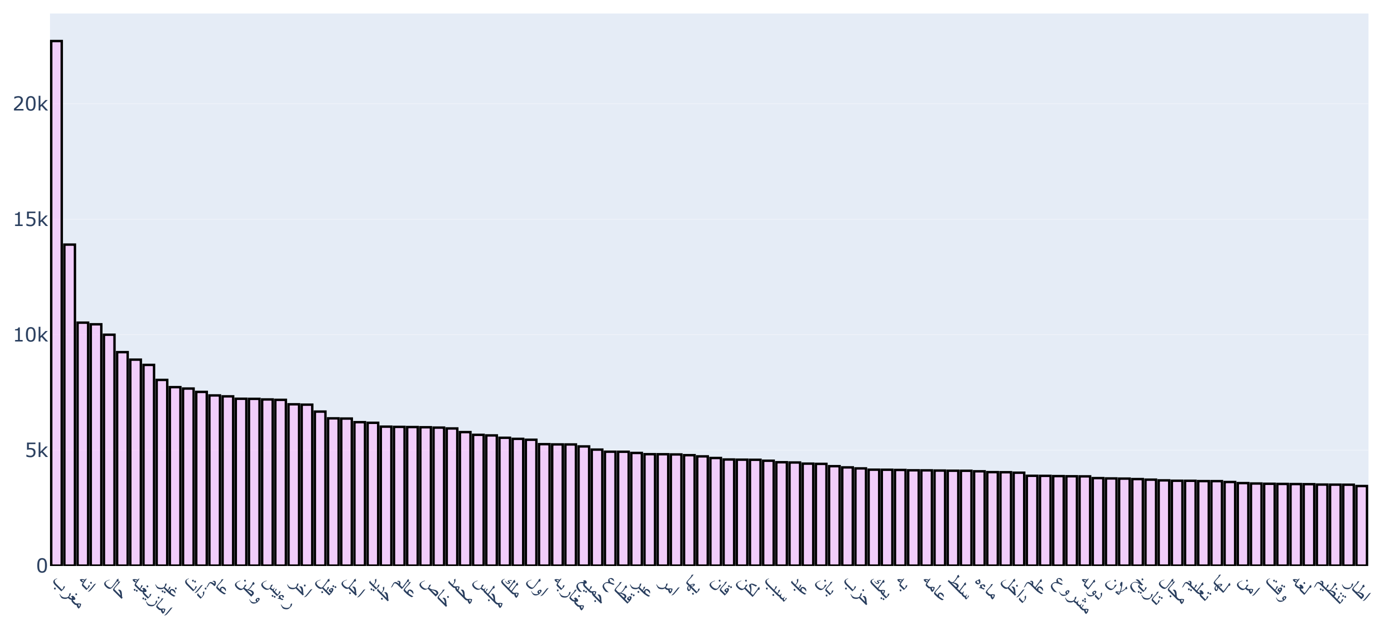

Bigram

```
In [66]: words=get_top_n_words(df["story"],100,2)
         df_gram=pd.DataFrame(words,columns=["Bigram","Count"])
         data = go.Bar(
                         x = df_gram["Bigram"],
                         y = df_gram["Count"],
                         name = "citations",
                         marker = dict(color = 'rgba(255, 174, 255, 0.5)',
                                      line=dict(color='rgb(0,0,0)',width=1.5)))
         fig = go.Figure(data = data)
         fig.update_xaxes(tickangle= 45)
         fig.update_layout(title_text="Distribution of bigram",title_x=0.5)

         iplot(fig)
         ## now we see the top 100 words bigram distribution
```

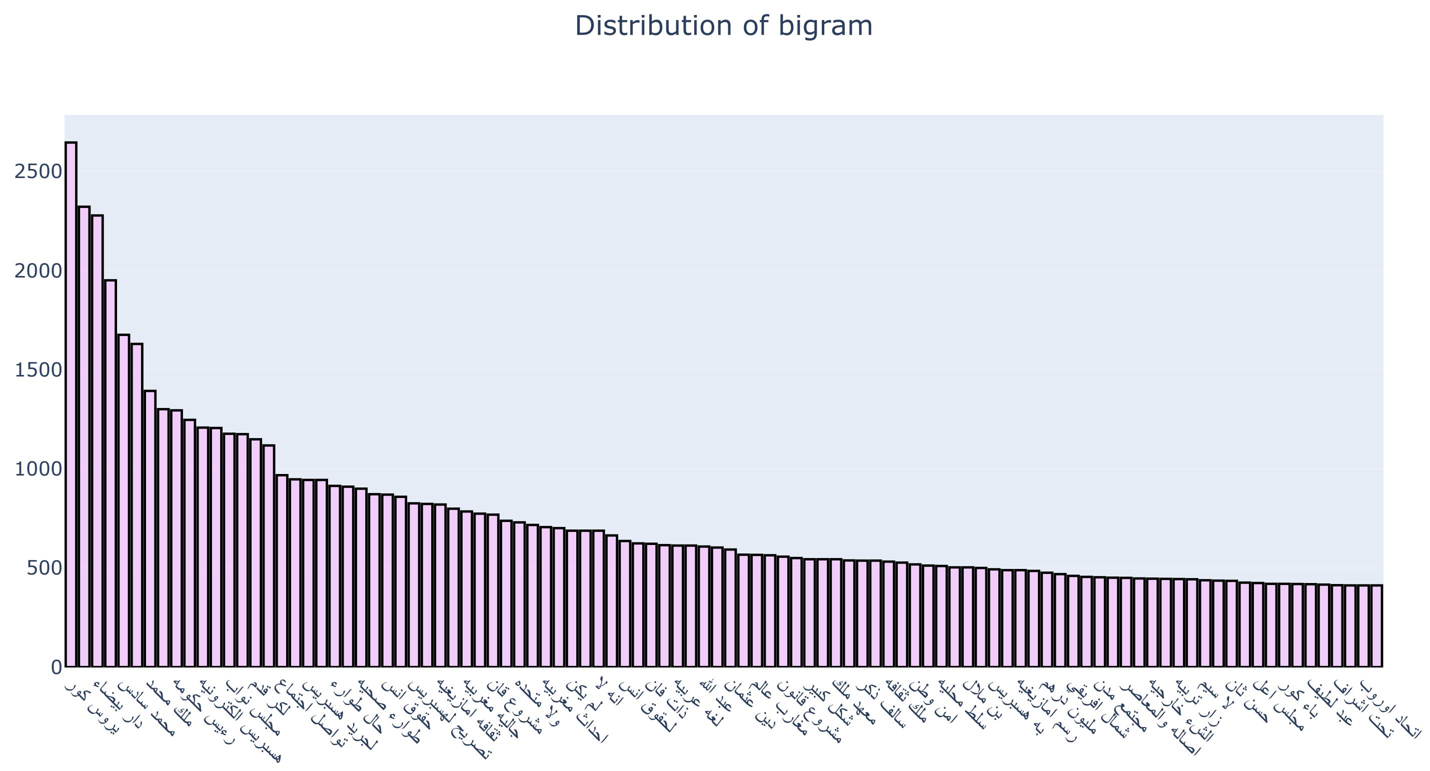

Trigram

In [67]:
```python
words=get_top_n_words(df["story"],100,3)
df_gram=pd.DataFrame(words,columns=["Bigram","Count"])
data = go.Bar(
                x = df_gram["Bigram"],
                y = df_gram["Count"],
                name = "citations",
                marker = dict(color = 'rgba(255, 174, 255, 0.5)',
                             line=dict(color='rgb(0,0,0)',width=1.5)))
fig = go.Figure(data = data)
fig.update_xaxes(tickangle= 45)
fig.update_layout(title_text="Distribution of Trigram",title_x=0.5)

iplot(fig)
## now we see the top 100 words Trigram distribution
```

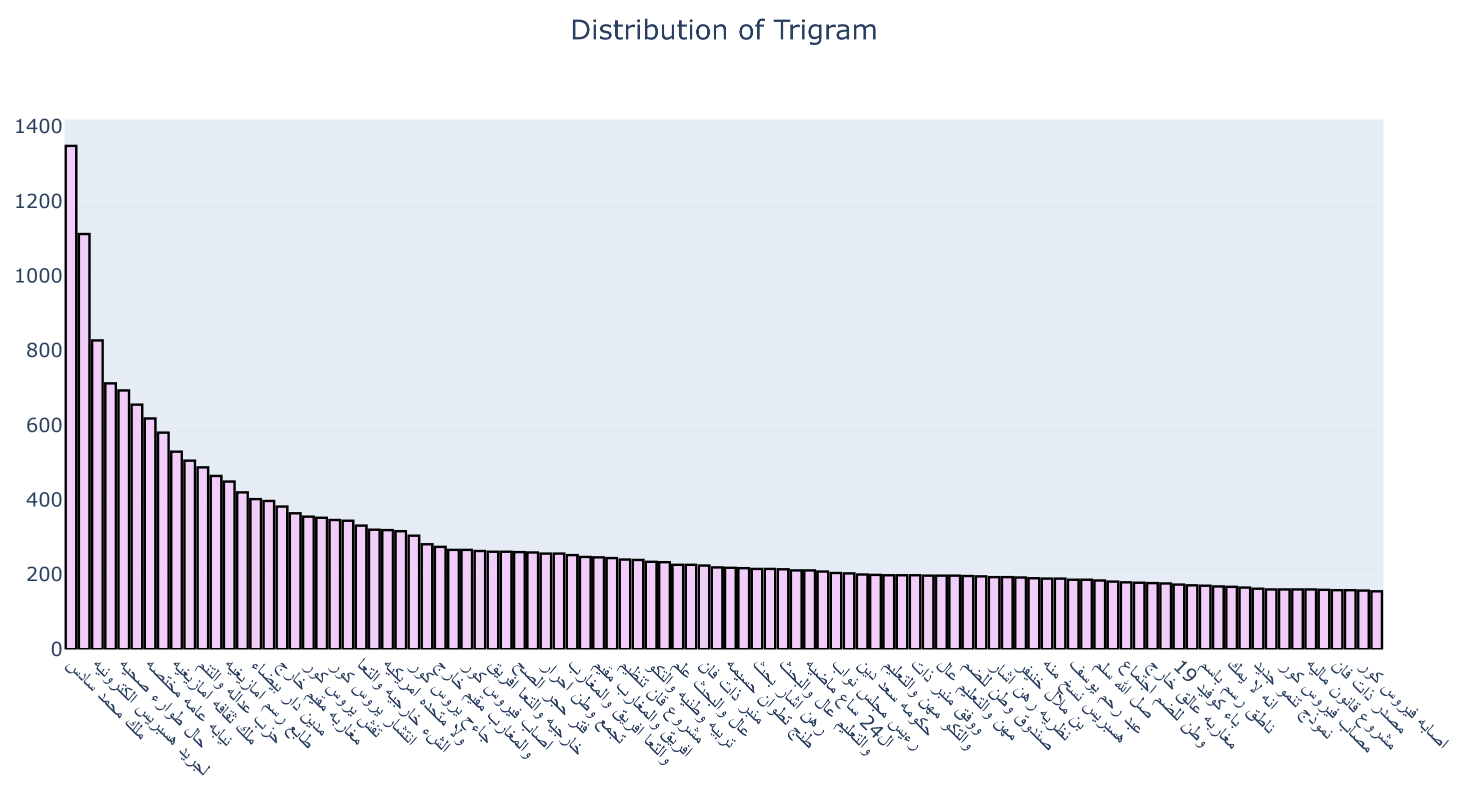

Save Dataset

```
In [68]: df.to_csv("task2.csv",index=False)
```